



INFORME FINAL DE EXPERIMENTACIÓN:

Optimización Predictiva del Triage en Austin Animal Center

Integrantes: Calderón Gabriel - Guerrero Emilio - Salazar Eduardo

Fecha: 2026-06-19

1. Introducción

El presente experimento abordó la vulnerabilidad logística crónica del Austin Animal Center (AAC), derivada de su estatus "No-Kill" y la asimetría temporal en el flujo de adopciones. El objetivo principal consistió en evaluar la viabilidad de transicionar de un modelo de asignación heurístico (estimaciones manuales del personal) hacia un motor predictivo basado en Aprendizaje Automático para calcular el Tiempo de Permanencia (Length of Stay - LOS). Los datos recolectados provinieron del registro histórico oficial de ingresos y desenlaces del AAC, abarcando decenas de miles de registros fenotípicos y demográficos procesados para evitar la fuga de datos.

2. Metodología y Diseño Experimental

El diseño experimental se estructuró mediante una validación cruzada temporal (Temporal Split). Se utilizó el histórico anterior a 2017 como conjunto de entrenamiento y los datos a partir del 1 de enero de 2017 como conjunto de prueba, simulando rigurosamente el entorno de producción.

Se definieron dos grupos de evaluación predictiva:

- **Grupo de Control (Métrica Base):** Un modelo de Regresión Lineal Múltiple, representativo de la inferencia estadística paramétrica tradicional.
 - **Grupo Experimental:** Un modelo de ensamble de árboles de decisión (HistGradientBoostingRegressor / XGBoost), capaz de modelar relaciones no
- 

lineales.

Previo al entrenamiento, se aplicó una transformación logarítmica $\log(1 + x)$ a la variable dependiente para mitigar la asimetría positiva severa de los datos.

Adicionalmente, se ejecutó un *pipeline* de ingeniería de características (*Feature Engineering*) extrayendo heurísticas lógicas a partir de cadenas de texto (ej.

categorización por tamaño de raza `breed_size`, banderas booleanas de edad extrema `is_puppy_kitten`, `is_senior` e identificación de razas estigmatizadas como `is_pitbull`).

3. Resultados y Análisis de Datos

La evaluación empírica sobre el conjunto de prueba arrojó resultados concluyentes a favor de las arquitecturas no lineales:

Modelo Predictivo	Coefficiente de Determinación (R^2)	Error Absoluto Mediano (MedAE)	Raíz del Error Cuadrático Medio (RMSE)
Regresión Lineal (Control)	0.068	4.48 días	28.31 días
Gradient Boosting (XGBoost)	0.139	3.91 días	27.41 días

Identificación de Patrones:

1. **Fracaso de la Linealidad:** El Grupo de Control demostró que el fenómeno de la



adopción no obedece a proporciones lineales. La Regresión Lineal fue incapaz de aislar el efecto combinado de variables categóricas complejas, perdiendo precisión frente a estimaciones estáticas.

2. **Jerarquía de Variables (Permutation Importance):** El análisis de explicabilidad global reveló que el tamaño de la raza (**breed_size**), la edad al ingreso (**age_in_years**) y el estado reproductivo (**sex_upon_intake**) son los predictores estructurales primarios. Factores como el fenotipo "Pitbull" actúan como multiplicadores secundarios de retención.

4. Discusión de la Experimentación

Los hallazgos del experimento validan la hipótesis alternativa: la implementación de *Gradient Boosting* optimizado reduce significativamente el error de predicción logística. Sin embargo, la interpretación profunda de los resultados requiere un juicio ingenieril crítico respecto a dos fenómenos particulares observados:

- **La Paradoja del Coeficiente de Determinación (R^2):** A nivel teórico, un R^2 de 0.14 podría considerarse deficiente en sistemas físicos aislados. No obstante, en ecosistemas biológicos y sociológicos, este valor cuantifica matemáticamente la **Varianza Latente**. El tiempo de estadía de un animal depende masivamente de variables no observadas en el triaje inicial (ej. temperamento subyacente, calidad de la fotografía de marketing, capacidad mensual de la red de *fosters*). El modelo alcanzó el límite teórico predictivo dados los datos disponibles, logrando aun así un margen de error operativo (MedAE) menor a 4 días en la mitad de los casos. (3.4. *Metrics and Scoring*, s. f.; 5.8 *Evaluating point forecast accuracy | Forecasting*, s. f.; Hyndman & Koehler, 2006)
- **Explicabilidad Local (SHAP) y la Realidad Operativa:** El escrutinio de casos individuales mediante Valores de Shapley desmintió preconcepciones humanas.



Por ejemplo, el modelo demostró que edades extremadamente geriátricas combinadas con condiciones de enfermedad no aumentan la retención logística, sino que la colapsan drásticamente debido a resoluciones médicas rápidas (eutanasia compasiva o traslados a cuidados paliativos). («Length of Stay (LOS)», s. f.)

Estos resultados superan los enfoques previos basados puramente en promedios históricos, demostrando que un modelo de caja blanca (explicable) puede guiar la toma de decisiones sin depender de la "caja negra" del sesgo humano.

5. Conclusiones

1. **Viabilidad Arquitectónica:** El algoritmo *HistGradientBoosting* demostró ser la arquitectura óptima para lidiar con la dispersión categórica y la asimetría continua intrínseca a los sistemas de gestión de refugios.
2. **Impacto Operativo:** Reducir la incertidumbre logística a una ventana típica de ± 3.9 días en el Día 0 permite a la administración transicionar de un sistema reactivo a uno preventivo, detonando alertas automatizadas de marketing para los perfiles categorizados como "Riesgo Alto".
3. **Límites del Sistema:** Se concluye que el modelo actúa matemáticamente como un calculador de riesgo basal y no como un oráculo determinista. Las discrepancias extremas (errores residuales altos) son síntomas sistémicos de factores exógenos o conductuales no parametrizados en la puerta de ingreso.

6. Recomendaciones para Futuras Investigaciones

Para futuras iteraciones del desarrollo de este producto de software, se sugieren las siguientes optimizaciones:

- **Expansión de la Matriz de Características:** Integrar variables conductuales



tempranas (ej. resultados de pruebas de agresividad en el triaje) y variables exógenas (ej. densidad de ocupación del refugio al momento del ingreso).

- **Transición a Análisis de Supervivencia:** Investigar la aplicación de modelos de regresión de supervivencia (*Cox Proportional Hazards*) para lidiar matemáticamente con la censura de datos (animales que aún no han sido adoptados al momento del corte temporal).

7. Referencias

3.4. *Metrics and scoring: Quantifying the quality of predictions.* (s. f.). Scikit-Learn.

Recuperado 27 de junio de 2026, de

https://scikit-learn/stable/modules/model_evaluation.html

5.8 *Evaluating point forecast accuracy | Forecasting: Principles and Practice (3rd ed).*

(s. f.). Recuperado 27 de junio de 2026, de

<https://otexts.com/fpp3/accuracy.html>

Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679-688.

<https://doi.org/10.1016/j.ijforecast.2006.03.001>

Length of Stay (LOS). (s. f.). *Koret Shelter Medicine Program*. Recuperado 27 de junio de 2026, de

<https://www.sheltermedicine.com/library/resources/length-of-stay-los>